

Comparison of C4.5 and XGBoost Models with Hyperparameter Tuning for Mental Health Prediction

Jufourlisa Sirait¹, Kezia Hutagaol², Reinaldy Hutapea³, Tenny Pakpahan⁴

Github: <https://github.com/tennov1011/Project-Data-Mining.git>

INTISARI — Penelitian ini bertujuan untuk mengimplementasikan algoritma XGBoost dan Decision Tree C4.5 untuk memprediksi depresi berdasarkan faktor sosial, ekonomi, dan psikologis, menggunakan dataset Exploring Mental Health Data. Proses dilakukan dengan pendekatan CRISP-DM yang mencakup pemahaman bisnis, eksplorasi data, persiapan data, pembangunan model, evaluasi, hingga deployment. Hasil evaluasi menunjukkan bahwa XGBoost dengan Grid Search Tuning memberikan akurasi terbaik sebesar 93.91%, dengan precision mencapai 94.63% dan F1-score 83.06%, yang menunjukkan kemampuan model dalam mendeteksi individu yang berisiko depresi secara lebih akurat dibandingkan dengan Decision Tree C4.5. Faktor dominan yang berkontribusi terhadap prediksi depresi meliputi Academic Pressure, Age, dan Job Satisfaction. Penelitian ini diharapkan dapat membantu dalam mendeteksi depresi lebih dini dan memberikan wawasan baru untuk pengembangan kebijakan pencegahan masalah kesehatan mental.

KATA KUNCI — Mental Health, XGBoost, Grid Search, Decision Tree C4.5, CRISP-DM

I. PENDAHULUAN

1.1 Latar Belakang

Kesehatan mental sangat penting karena mempengaruhi kualitas hidup, produktivitas, dan kesejahteraan sosial. Depresi, salah satu gangguan mental yang umum, berdampak besar pada hubungan sosial dan kemampuan bekerja. Di Indonesia, kasus gangguan mental terus meningkat, terutama pada remaja dan dewasa muda, meskipun masih banyak yang enggan membicarakannya[1].

Proyek ini menggunakan dataset dari kompetisi Kaggle *Exploring Mental Health Data* yang berisi informasi sosial, ekonomi, dan psikologis terkait kesehatan mental. Dataset ini menjadi dasar untuk membangun model klasifikasi dengan tujuan utama mendeteksi depresi secara dini. Pendekatan ini sangat penting mengingat depresi merupakan salah satu gangguan mental yang cukup banyak dialami, namun seringkali sulit terdeteksi sejak awal.

Dalam proyek ini, dua algoritma machine learning dipilih, yaitu XGBoost dan Decision Tree C4.5 Style. XGBoost dipilih karena kemampuannya menghasilkan prediksi yang akurat dan proses pelatihan yang efisien, sementara Decision Tree C4.5 Style dikenal dengan model yang mudah dipahami serta kemampuannya mengidentifikasi faktor-faktor penting yang memengaruhi kondisi depresi. Kombinasi kedua metode ini diharapkan dapat memberikan gambaran yang komprehensif mengenai kondisi kesehatan mental berdasarkan data yang ada.

Untuk mengoptimalkan performa model, digunakan teknik Grid Search dalam proses hyperparameter tuning. Grid Search melakukan pencarian sistematis terhadap kombinasi parameter terbaik untuk meningkatkan akurasi dan mencegah overfitting dengan bantuan Cross Validation. Dengan metode ini, proyek diharapkan dapat menemukan pola-pola penting dalam data serta menghasilkan model prediksi depresi yang lebih handal dan berguna dalam aplikasi nyata di bidang kesehatan mental [2].

1.2 Tujuan

Adapun tujuan dari pelaksanaan proyek ini adalah:

1. Memenuhi salah satu syarat dalam penyelesaian mata kuliah yang berkaitan dengan penerapan machine learning dalam analisis kesehatan mental.
2. Membangun model klasifikasi yang dapat memprediksi apakah seseorang mengalami depresi atau tidak menggunakan algoritma machine learning, seperti XGBoost dan Decision Tree C4.5, Grid Search, dengan tujuan untuk membantu dalam mendeteksi masalah kesehatan mental secara lebih efektif.
3. Menganalisis faktor yang berkontribusi terhadap depresi berdasarkan dataset mental health, untuk mengidentifikasi faktor sosial, ekonomi, dan psikologis yang dapat mempengaruhi kesehatan mental seseorang, sehingga dapat memberikan wawasan yang lebih dalam dalam pencegahan dan penanganan depresi.

1.3 Manfaat

Proyek ini memberikan beberapa manfaat penting seperti:

1. Proyek ini dapat membantu mendeteksi depresi lebih dini dengan menggunakan metode machine learning seperti XGBoost, Decision Tree C4.5, dan Grid Search sehingga memungkinkan intervensi yang lebih cepat dan mengurangi dampak jangka panjang dari gangguan mental tersebut.
2. Dengan menganalisis faktor sosial, ekonomi, dan psikologis dalam dataset, proyek ini memberikan pemahaman yang lebih dalam mengenai faktor-faktor yang mempengaruhi kesehatan mental dan bagaimana faktor-faktor tersebut berkontribusi pada kondisi depresi.
3. Hasil dari analisis ini dapat digunakan untuk merancang kebijakan pencegahan yang lebih tepat dalam mengatasi depresi, dengan mengandalkan

informasi yang lebih akurat mengenai berbagai faktor yang mempengaruhi kesehatan mental individu.

1.4 Ruang Lingkup

Ruang lingkup dalam proyek yang dikerjakan yaitu:

1. Proyek ini akan menggunakan dataset Exploring Mental Health Data dari Kaggle untuk melakukan eksplorasi data, mempersiapkan data untuk analisis, dan memastikan bahwa dataset yang digunakan berkualitas baik sebelum diproses lebih lanjut.
2. Model prediksi depresi akan dibangun menggunakan XGBoost, Decision Tree C4.5, dan Grid Search yang bertujuan untuk memprediksi apakah seseorang berisiko mengalami depresi berdasarkan data yang telah dianalisis dan diproses.
3. Proyek ini dilaksanakan dengan mengikuti langkah-langkah CRISP-DM (Cross-Industry Standard Process for Data Mining), yang terdiri dari tahap business understanding, data understanding, data preparation, modeling, evaluation, dan deployment. Setiap tahap akan dilakukan secara berurutan untuk memastikan proses analisis dan pembuatan model berjalan dengan baik.
4. Proyek ini berfokus pada membangun model klasifikasi untuk memprediksi depresi, serta menganalisis faktor-faktor yang berkontribusi terhadap kondisi tersebut. Analisis ini bertujuan untuk menemukan pola-pola signifikan yang dapat memberikan penyebab depresi.

1.5 Istilah dan Singkatan

Singkatan	Istilah
Riskesda	Riset Kesehatan Dasar
AI	Artificial Intelligence
CRISP-DM	Cross-Industry Standard Process for Data Mining
XGBoost	Extreme Gradient Boosting

II. STUDI LITERATURE

2.1 Mental Health

Kesehatan mental merupakan bagian penting dari kesejahteraan individu yang mencakup kondisi emosional, mental, dan sosial yang memengaruhi cara seseorang berpikir, merasakan, dan bertindak. Pada masa remaja, kesehatan mental sangat dipengaruhi oleh berbagai faktor seperti proses belajar, jenis kelamin, dan tingkat pendidikan [3]. Remaja sering menghadapi tekanan dan tantangan yang jika tidak dikelola dengan baik dapat menyebabkan gangguan mental seperti kecemasan dan depresi. Oleh karena itu, perhatian khusus terhadap kesehatan mental di usia ini sangat penting untuk mencegah dampak negatif di masa depan.

Selain itu, kesehatan mental di tempat kerja juga menjadi perhatian penting, terutama karena stres kerja yang tinggi, khususnya di sektor manufaktur yang menuntut kinerja cepat

dan tinggi. Stres yang berlebihan dan kurangnya keseimbangan antara kehidupan pribadi dan pekerjaan dapat memicu gangguan mental seperti depresi dan kecemasan [4]. Oleh sebab itu, perusahaan perlu menciptakan lingkungan kerja yang mendukung kesehatan mental karyawan agar produktivitas dan kesejahteraan mereka meningkat. Secara keseluruhan, menjaga kesehatan mental sangat krusial agar kita dapat hidup lebih bahagia, produktif, dan memiliki hubungan sosial yang lebih baik.

2.2 XGBoost

XGBoost (Extreme Gradient Boosting) adalah algoritma machine learning yang digunakan untuk klasifikasi dan prediksi dengan menggabungkan beberapa model prediksi untuk meningkatkan akurasi. Algoritma ini memanfaatkan teknik gradient boosting, di mana model baru memperbaiki kesalahan model sebelumnya[5]. XGBoost sangat efisien dalam menangani data besar dan kompleks berkat penggunaan multi-threading dan pruning, serta dilengkapi dengan fitur regularization untuk mencegah overfitting.

XGBoost efektif dalam mengolah data yang tidak terstruktur dan fitur yang saling berhubungan, menjadikannya populer dalam berbagai aplikasi seperti prediksi harga, deteksi anomali, dan klasifikasi gambar. Algoritma ini dapat menangani berbagai jenis data, termasuk data dengan outlier, missing values, dan distribusi yang berubah, sehingga tetap menghasilkan model yang akurat meskipun data memiliki tantangan atau kualitas rendah.

2.3 Grid Search

Grid Search adalah metode untuk mencari kombinasi hyperparameter terbaik dalam machine learning dengan menguji semua kombinasi yang telah ditentukan dan memilih yang memberikan performa model terbaik. Metode ini membantu mengoptimalkan kinerja algoritma dengan mengeksplorasi berbagai kemungkinan secara sistematis sehingga model yang dihasilkan menjadi lebih optimal.

Menurut Nugraha dan Sasongko, Grid Search digunakan untuk mengoptimalkan hyperparameter pada beberapa algoritma klasifikasi seperti XGBoost, SVM, dan Decision Tree, terbukti efektif dalam meningkatkan akurasi model, contohnya pada dataset diabetes Pima Indian. Eksperimen menunjukkan XGBoost mendapat skor tertinggi 0,772, sementara Decision Tree nilai terendah [2]. Penggunaan Cross Validation dalam Grid Search memudahkan evaluasi tiap kombinasi, namun proses ini bisa memakan waktu lama terutama saat jumlah parameter yang diuji bertambah banyak [2].

2.4 Decision Tree C4.5.

Decision Tree C4.5 merupakan algoritma klasifikasi yang dikembangkan oleh J. Ross Quinlan sebagai penyempurnaan dari ID3. Algoritma ini menggunakan information gain ratio untuk memilih atribut terbaik, dapat menangani data numerik, nilai yang hilang, serta melakukan pruning untuk menyederhanakan model. Dalam sebuah penelitian, algoritma ini berhasil mengklasifikasikan risiko diabetes dengan akurasi 90,38%, di mana atribut polydipsia menjadi akar pohon keputusan karena memiliki nilai gain ratio tertinggi[6].

Penelitian sebelumnya menunjukkan bahwa algoritma C4.5 memiliki kinerja yang lebih baik dibandingkan ID3, terutama dalam hal fleksibilitas dan ketepatan. C4.5 mampu menangani

data kompleks, seperti data numerik, data yang hilang, dan juga melakukan *pruning* untuk menyederhanakan model. Algoritma ini banyak digunakan di berbagai bidang, seperti evaluasi akademik, prediksi penyakit, dan analisis bisnis, karena dapat menghasilkan model klasifikasi yang akurat, mudah dipahami, dan mudah diinterpretasikan.

2.5 CRISP-DM

CRISP-DM (CRoss Industry Standard Process for Data Mining) adalah metode standar untuk membantu menjalankan proyek data mining agar lebih terstruktur dan efisien. CRISP-DM bisa digunakan di berbagai bidang dan teknologi, karena bersifat fleksibel. Proses CRISP-DM dibagi menjadi enam fase utama: Business Understanding (memahami tujuan bisnis), Data Understanding (memahami data yang ada), Data Preparation (mempersiapkan data untuk analisis), Modeling (membangun model analisis), Evaluation (menilai hasil model), dan Deployment (menggunakan model yang sudah dibangun). Setiap fase memiliki langkah-langkah yang jelas namun tetap bisa disesuaikan dengan kondisi dan kebutuhan proyek[7].

CRISP-DM adalah metode yang membantu merencanakan, berkomunikasi, dan mendokumentasikan proses data mining secara sistematis. Dimulai dari *Business Understanding* untuk memahami tujuan bisnis dan mengubahnya menjadi masalah data, dilanjutkan dengan *Data Understanding* untuk mengeksplorasi pola atau masalah dalam data. Tahap *Data Preparation* menyiapkan data mentah untuk pemodelan, lalu di *Modeling* dipilih teknik analisis yang sesuai. Setelah itu, *Evaluation* menilai apakah model sudah memenuhi tujuan, dan *Deployment* menerapkan model dalam praktik. Metode ini cocok digunakan baik oleh pemula maupun profesional.

III. METODE PENELITIAN

Proyek ini menggunakan model *Cross Industry Standard Process for Data Mining* (CRISP-DM) dalam pelaksanaannya untuk mencapai tujuan yang telah ditetapkan. CRISP-DM merupakan model yang dirancang untuk memandu dalam setiap tahap proyek data mining. Model ini mencakup beberapa fase, tugas umum, serta tugas spesifik yang memungkinkan pengguna untuk merencanakan dan mendokumentasikan proyek secara efektif. Fase utama dalam CRISP-DM meliputi pemahaman bisnis (*business understanding*), pemahaman data (*data understanding*), persiapan data (*data preparation*), pemodelan (*modelling*), evaluasi (*evaluation*), dan penerapan (*deployment*).

3.1 Business Understanding

Tujuan utama dari analisis ini adalah untuk membantu memahami dan mendeteksi depresi pada individu dengan menggunakan data kesehatan mental yang tersedia. Dengan membangun model prediksi berbasis data, proyek ini bertujuan untuk mengidentifikasi siapa saja yang berisiko mengalami depresi dan apa saja faktor yang mempengaruhinya.

Informasi yang didapat dari model ini akan sangat berguna bagi lembaga kesehatan seperti psikiater dan rumah sakit dalam merencanakan perawatan yang tepat bagi individu yang berisiko depresi. Dengan prediksi yang lebih akurat, mereka bisa mengalokasikan sumber daya seperti tenaga medis dan dukungan psikologis sesuai dengan kebutuhan di lapangan.

Beberapa manfaat yang diharapkan dari proyek ini adalah:

1. Dengan mengetahui siapa saja yang berisiko mengalami depresi, lembaga kesehatan bisa memberikan perhatian lebih awal kepada mereka yang membutuhkan bantuan, sehingga mencegah masalah menjadi lebih serius.
2. Model prediksi dapat membantu rumah sakit atau klinik dalam merencanakan tenaga medis dan layanan psikologi yang dibutuhkan berdasarkan tingkat risiko depresi yang ditemukan di masyarakat.
3. Dengan mengetahui faktor-faktor yang mempengaruhi depresi, perawatan bisa lebih fokus dan disesuaikan dengan kebutuhan individu.
4. Dengan mendeteksi depresi lebih awal dan memberikan perawatan yang lebih baik, proyek ini dapat membantu mengurangi biaya pengobatan jangka panjang dan mengurangi dampak negatif depresi pada individu dan masyarakat.

Secara keseluruhan, dengan pendekatan berbasis data ini, diharapkan bisa membantu menangani masalah kesehatan mental lebih efektif dan efisien, serta memberikan manfaat positif bagi masyarakat.

3.2 Data Understanding

Data Understanding membantu dalam mengidentifikasi karakteristik, pola, dan kualitas data yang akan diolah. Tanpa pemahaman yang baik, proses data mining bisa menghasilkan interpretasi yang salah dan keputusan yang tidak tepat. Berikut adalah beberapa hal yang dilakukan pada tahapan ini dalam proyek *Exploring Mental Health*:

a. Collecting Data

Mengumpulkan data yang diperlukan untuk analisis, termasuk informasi terkait faktor sosial, ekonomi, dan psikologis yang mempengaruhi kondisi mental individu. Dataset yang digunakan dalam proyek ini berasal dari kompetisi Kaggle *Exploring Mental Health Data*, yang terdiri dari dua bagian utama: *train.csv* untuk pelatihan model dan *test.csv* untuk pengujian model. Data ini mencakup informasi penting seperti jenis kelamin, usia, status pekerjaan, tingkat pendidikan, tekanan sosial, dan banyak lagi yang relevan dengan kesehatan mental, khususnya depresi.

b. Describe Data

Melakukan eksplorasi awal untuk memahami distribusi data, serta variasi pada fitur-fitur yang relevan dengan kondisi mental individu. Beberapa fitur yang dianalisis meliputi:

- **Data Kategorikal:** Gender, City, Degree, Working Professional or Student Profession, Sleep Duration, Dietary Habits, Have you ever had suicidal thoughts?, Family History of Mental Illness, yang dapat mempengaruhi kondisi mental seseorang.
- **Data Numerik:** Age, Academic Pressure, Work Pressure, CGPA, Study Satisfaction, Job Satisfaction, Work/Study Hours, Financial Stress, Depression, yang memberikan gambaran terkait gaya hidup dan faktor-faktor yang dapat mempengaruhi stres dan kesehatan mental.

Dataset ini terdiri dari 140.700 data train dan 93.800 data test dengan 17 fitur terkait kesehatan mental. Mayoritas data menunjukkan nama "Rohan", gender "Male", usia rata-rata sekitar 40–41 tahun, dan dominasi kota "Kalyan" serta profesi "Working Professional". Academic Pressure rata-rata sekitar 3, menunjukkan tekanan akademik sedang. Dataset bersih tanpa nilai kosong dan siap dianalisis. Analisis korelasi mengungkap usia berbanding terbalik dengan depresi (-0,56), sedangkan Academic Pressure (0,48) dan Work Pressure (0,22) berkorelasi positif. Kepuasan kerja dan studi memiliki korelasi negatif dengan depresi (-0,17 dan -0,29), menandakan bahwa tekanan akademik dan kepuasan hidup berpengaruh signifikan pada kondisi mental.

c. Validation Data

Memastikan data yang dikumpulkan valid dan berkualitas agar tidak mempengaruhi akurasi model prediksi. Beberapa langkah yang dilakukan untuk memvalidasi data adalah:

- Pemeriksaan missing values, yakni memeriksa apakah ada data yang hilang pada kolom atau baris yang memerlukan penanganan, seperti pengisian, penghapusan, atau pengolahan lebih lanjut. Dari hasil, yang memiliki missing values adalah kolom Profession, Academic Pressure, Work Pressure, CGPA, Study Satisfaction, Job Satisfaction, Dietary Habits, Degree, Financial Stress.
- Pemeriksaan duplikasi, yakni mengecek apakah ada data yang terduplikasi, jika ada dapat mempengaruhi hasil analisis. Namun, pada dataset ini tidak ada data yang duplikat, baik dari data train maupun test.
- Pemeriksaan outlier dilakukan untuk mengidentifikasi nilai ekstrem pada fitur kategorikal dan numerikal. Pada fitur kategorikal seperti *Age*, meskipun distribusinya merata, terdapat puncak di usia 50-an yang bisa menjadi indikasi data tidak biasa. *Academic Pressure* dan *Work Pressure* juga menunjukkan konsentrasi nilai pada angka tertentu, seperti 3, yang dapat menandakan outlier. Nilai *CGPA* sebagian besar tersebar, namun ada beberapa nilai sangat tinggi yang patut dicermati. *Study Satisfaction* dan *Job Satisfaction* menunjukkan kepuasan umum, namun tetap perlu diperhatikan nilai-nilai ekstremnya. *Work/Study Hours* memiliki distribusi luas, dengan jam yang sangat tinggi atau rendah yang berpotensi sebagai outlier. Sementara itu, pada fitur numerikal secara keseluruhan tidak terdeteksi adanya outlier.

Dengan melakukan langkah-langkah ini, diharapkan data yang digunakan untuk membangun model dapat menghasilkan analisis yang akurat dan efektif dalam memprediksi kondisi mental individu, khususnya depresi.

3.3 Data Preparation

Data Preparation adalah tahap yang sangat penting dalam memastikan bahwa data yang digunakan dalam analisis sudah siap untuk digunakan dalam proses pemodelan. Tanpa persiapan yang baik, kualitas model yang dibangun bisa terpengaruh dan menghasilkan analisis yang tidak akurat. Berikut adalah beberapa langkah yang dilakukan dalam tahapan ini dalam proyek *Exploring Mental Health*:

a. Data Selection

Pada tahap Memilih Data, dilakukan pemilihan data yang relevan dengan tujuan analisis berdasarkan uji Chi-Square dan korelasi antara fitur-fitur numerik dan kategorikal terhadap status Student atau Working Professional. Atribut yang memiliki p-value < 0.05 dianggap signifikan dan dipertahankan untuk dimasukkan ke dalam model prediksi. Berdasarkan hasil uji, atribut yang dipertahankan untuk proses modeling adalah Gender, City, Degree, Profession, Sleep Duration, dan Have you ever had suicidal thoughts?, yang semuanya menunjukkan hubungan signifikan dengan status mahasiswa atau profesional.

b. Data Cleaning

Pada tahap ini yang dilakukan adalah untuk Menghilangkan data yang tidak relevan atau bermasalah agar data yang digunakan berkualitas dan tidak mempengaruhi hasil model. Langkah-langkah yang dilakukan untuk membersihkan data adalah:

- Data yang hilang di kolom numerik diisi dengan median dan di kolom kategorikal dengan modus, yang menjamin data yang hilang diisi dengan nilai yang representatif.
- Memeriksa dan menghapus baris data yang terduplikasi menggunakan fungsi duplicated(). Hasilnya menunjukkan tidak ada data yang terduplikasi, yang memastikan bahwa dataset tidak terdistorsi.
- Memeriksa adanya nilai ekstrem (outliers) yang bisa mempengaruhi hasil analisis. Pemeriksaan dilakukan pada fitur numerik seperti Age, CGPA, dan Work/Study Hours, dan tidak ditemukan outliers yang signifikan.

c. Data Construction

Pada tahap Mengkonstruksi Data, beberapa langkah dilakukan untuk menambah fitur baru dan melakukan transformasi data agar lebih relevan dan informatif untuk model prediksi:

• Normalisasi

Beberapa fitur numerik seperti Age, Work/Study Hours, Financial Stress, dan Work Pressure dinormalisasi menggunakan MinMaxScaler agar nilai fitur berada dalam rentang 0 hingga 1. Normalisasi ini penting agar semua fitur memiliki kontribusi yang setara dalam proses pelatihan model, khususnya untuk model yang sensitif terhadap perbedaan skala antar fitur.

• Feature Engineering

Kolom seperti Sleep Duration dan Dietary Habits yang memiliki urutan tingkatannya diubah menjadi format numerik menggunakan mapping

logis. Selain itu, dibuat fitur baru yaitu *Stress_Score*, yang merupakan hasil penjumlahan dari *Work Pressure* dan *Financial Stress*, untuk menggambarkan tingkat stres keseluruhan individu.

d. Labeling Data

Pada tahap Labeling Data, fitur kategorikal diubah menjadi format numerik agar dapat digunakan dalam model. Fitur biner seperti "Have you ever had suicidal thoughts?", "Family History of Mental Illness", dan "Gender" dikodekan dengan binary encoding (0 dan 1). Fitur nominal dengan lebih dari dua kategori seperti Degree, Profession, dan City menggunakan category encoding. Selain itu, fitur "Working Professional or Student" diubah dengan Label Encoding (0 untuk Student, 1 untuk Working Professional). Konsistensi proses encoding antara data latih dan data uji sangat penting untuk menghindari kesalahan prediksi.

e. Data Integration

Menggabungkan data yang diperlukan untuk analisis lebih lanjut. Namun, dalam proyek ini, proses mengintegrasikan data tidak dilakukan karena seluruh data yang dibutuhkan sudah tersedia dalam satu dataset utama, yaitu *Exploring Mental Health*. Dataset ini sudah mencakup semua informasi yang relevan

3.4 Modeling

Pada tahap Modeling, eksperimen klasifikasi dilakukan untuk memprediksi apakah seseorang mengalami depresi berdasarkan dataset yang ada. Proyek ini membandingkan tiga model klasifikasi: C4.5 Decision Tree, XGBoost (Extreme Gradient Boosting), dan XGBoost dengan Tuning GridSearch. Tujuan dari tahap ini adalah untuk mengevaluasi kinerja masing-masing model dalam mendeteksi depresi.

a. Building Testing Scenario

- **Persiapan Data**

Data yang hilang pada kolom numerik diisi dengan median, sementara kolom kategorikal diisi dengan modus. Fitur kategorikal yang ada seperti Gender, City, dan Profession diubah menjadi format numerik menggunakan LabelEncoder atau OneHotEncoder. Meskipun XGBoost tidak terlalu sensitif terhadap skala data, normalisasi tetap dilakukan untuk membantu konvergensi model. Untuk C4.5, normalisasi tidak diwajibkan, namun tetap disarankan jika ada perbedaan skala yang besar antar fitur. Setelah itu, data dibagi menjadi 80% untuk pelatihan dan 20% untuk pengujian. Kolom Depression digunakan sebagai target y, dan kolom Name dihapus karena tidak relevan untuk prediksi.

- **Pemilihan Model**

C4.5 Decision Tree digunakan untuk membangun model pohon keputusan dengan menggunakan Gain Ratio. Model ini dilengkapi dengan teknik pruning untuk menghindari overfitting, namun bisa mengalami overfitting jika tidak dibatasi kedalamannya. XGBoost, di

sisi lain, adalah algoritma ensemble learning berbasis gradient boosting yang menggabungkan banyak pohon keputusan lemah untuk membentuk model yang lebih kuat. XGBoost efektif dalam menangani data besar dan kompleks dan memiliki regularisasi untuk mencegah overfitting.

- **Evaluasi Model**

Model-model yang dibangun dievaluasi menggunakan metrik akurasi, precision, recall, F1-score, dan confusion matrix untuk membandingkan seberapa baik kedua model mendeteksi depresi.

- **Perbandingan Model**

Setelah evaluasi, C4.5 dan XGBoost dibandingkan berdasarkan akurasi, precision, recall, F1-score, dan confusion matrix untuk melihat model mana yang lebih efektif dalam mendeteksi depresi.

- **Penyempurnaan Model**

Penyempurnaan model dilakukan menggunakan GridSearchCV untuk menyesuaikan hyperparameter pada XGBoost. Hyperparameter seperti *n_estimators*, *learning_rate*, *max_depth*, *subsample*, dan *colsample_bytree* disesuaikan untuk mengoptimalkan performa model dan mencegah overfitting.

b. Building Model

Pada tahap Building Model, tiga model utama dipertimbangkan untuk memprediksi depresi berdasarkan data yang telah dipersiapkan.

- **C4.5 (Decision Tree)**

C4.5 adalah algoritma pohon keputusan yang menggunakan Gain Ratio untuk memilih pembagian terbaik dalam data. C4.5 dilengkapi dengan teknik pruning untuk menghindari overfitting, dan cukup mudah dipahami serta diinterpretasi. Model ini diterapkan dengan parameter *criterion='entropy'* untuk menggunakan information gain dalam membagi data, dan *max_depth=8* untuk membatasi kedalaman pohon agar model tidak terlalu kompleks.

- **XGBoost (Extreme Gradient Boosting)**

XGBoost adalah algoritma ensemble learning berbasis gradient boosting yang menggabungkan banyak pohon keputusan lemah untuk membentuk model yang kuat. XGBoost mendukung optimasi seperti regularisasi, early stopping, dan parallel processing untuk menangani overfitting. Parameter utama yang digunakan dalam model ini adalah *n_estimators=1000*, *learning_rate=0.2*, *max_depth=4*, *subsample=0.5*, dan *colsample_bytree=0.8*.

- **XGBoost dengan Tuning GridSearch**

Untuk meningkatkan performa XGBoost, dilakukan GridSearchCV untuk menemukan kombinasi hyperparameter terbaik. Dalam pencarian 64 kombinasi parameter, hasil terbaik

diperoleh dengan `n_estimators=200`, `max_depth=3`, `min_child_weight=1`, `subsample=0.7`, `colsample_bytree=1.0`, dan `learning_rate=0.2`. Konfigurasi ini menunjukkan bahwa model dengan kedalaman pohon yang relatif dangkal namun memiliki banyak pohon (estimators) dapat memberikan performa yang sangat baik. Model ini mencapai akurasi validasi silang sebesar 94%.

3.5 Evaluation

Pada fase ini, dilakukan evaluasi untuk memastikan model memenuhi tujuan prediksi status kesehatan mental. Beberapa langkah yang dilakukan pada tahap ini adalah sebagai berikut:

a. Pengukuran Performa Model

Model yang telah dilatih dievaluasi menggunakan beberapa metrik kinerja, termasuk akurasi, precision, recall, dan F1-score. Metrik-metrik ini memberikan gambaran tentang kemampuan model dalam memprediksi dengan benar, terutama dalam mendeteksi kedua kelas, yaitu individu yang berisiko mengalami depresi (suicidal) dan yang tidak (non-suicidal).

b. Evaluasi pada Data Uji

Setelah pelatihan, model diuji pada data uji yang terpisah. Prediksi dilakukan menggunakan metode **predict**, yang memberikan hasil prediksi kelas langsung. Kemudian, dilakukan perhitungan accuracy score, pembuatan classification report untuk mendapatkan rincian precision, recall, F1-score, dan confusion matrix untuk menganalisis distribusi kesalahan klasifikasi.

c. Perbandingan Model

Untuk mengetahui model mana yang paling baik, dilakukan perbandingan antara beberapa model yang berbeda, seperti C4.5 (Decision Tree) dan XGBoost. Evaluasi dilakukan terhadap masing-masing model, baik yang sudah melalui tuning hyperparameter (seperti menggunakan GridSearch untuk XGBoost) maupun yang tidak. Hal ini bertujuan untuk melihat pengaruh tuning terhadap peningkatan kinerja model.

d. Analisis Fitur Dominan

Selain mengukur performa model, dilakukan analisis terhadap fitur-fitur yang paling berpengaruh dalam proses prediksi. Fitur-fitur dominan ini membantu untuk memahami faktor-faktor utama yang mempengaruhi keputusan model dalam mengklasifikasikan individu berisiko mengalami depresi.

3.6 Deployment

Pada tahap Deployment, model yang telah dibangun dan diuji perlu diterapkan pada platform yang dapat digunakan untuk prediksi secara langsung. Proses deployment ini dilakukan dengan dua cara: deployment lokal menggunakan Flask dan deployment online menggunakan Streamlit.

a. Local

Pada tahap deployment model secara lokal, langkah pertama adalah menyimpan model yang telah dilatih agar dapat digunakan kembali pada aplikasi web yang akan dijalankan. Model yang telah dibangun, baik itu XGBoost atau model lainnya, disimpan menggunakan pickle untuk mempermudah pemanggilan model yang telah dilatih di aplikasi. Begitu juga dengan scaler yang digunakan untuk normalisasi data input, seperti StandardScaler atau MinMaxScaler.

Setelah model dan scaler disimpan, langkah berikutnya adalah membuat aplikasi Flask untuk menjalankan model yang telah dilatih. Flask adalah framework web ringan untuk membuat aplikasi berbasis web dengan cepat. Di dalam aplikasi Flask, model yang telah disimpan dan scaler akan dimuat untuk melakukan prediksi berdasarkan data yang dimasukkan oleh pengguna.

Flask berguna untuk membangun antarmuka pengguna (frontend) yang menerima input melalui form. Setelah data dimasukkan, aplikasi akan memproses data tersebut, melakukan normalisasi menggunakan scaler yang telah dimuat, dan kemudian mengirim data tersebut ke model untuk memprediksi apakah individu tersebut berisiko mengalami depresi atau tidak. Hasil prediksi akan ditampilkan kepada pengguna di halaman yang sama.

Untuk menjalankan aplikasi secara lokal, perlu memastikan bahwa server Flask berjalan pada mesin lokal yang dapat diakses di localhost pada port 5001. Aplikasi ini dapat diakses oleh pengguna melalui browser dengan URL <http://127.0.0.1:5001/>. Setelah pengguna mengisi form dengan data yang diperlukan, seperti usia, jam kerja/studi, stres finansial, dan tekanan kerja, model akan melakukan prediksi apakah individu tersebut berisiko mengalami depresi atau tidak. Hasil prediksi tersebut akan ditampilkan pada halaman yang sama, dengan teks yang menunjukkan apakah individu tersebut terdeteksi berisiko depresi atau tidak depresi, berdasarkan input yang diberikan.

b. Online

Untuk tahapan deployment secara online digunakan Streamlit. File model scaler yang sebelumnya sudah dibuat di deployment lokal juga dibuat pada deployment online. Kemudian, file `streamlit_app.py` dibuat untuk menjalankan aplikasi di Streamlit, yang berfungsi sebagai antarmuka pengguna untuk melakukan prediksi. Selanjutnya, dibuat file `requirements.txt` yang berisi daftar pustaka (library) yang diperlukan agar aplikasi berjalan dengan baik pada Streamlit service. Library tersebut akan diinstal otomatis oleh Streamlit sebelum aplikasi dijalankan. Setelah itu, file `streamlit_app.py` dimodifikasi agar bisa berfungsi dengan layanan Streamlit, termasuk menyesuaikan input dan output model agar sesuai dengan kebutuhan pengguna. Setelah semua file siap, deployment dapat dilakukan dengan menjalankan aplikasi melalui Streamlit Cloud. Aplikasi yang telah dideploy dapat diakses secara online menggunakan URL <https://project-data-mining-kel9.streamlit.app/>. Hasil prediksi dari model dapat dilihat langsung oleh

pengguna, yang menunjukkan bahwa proses deployment berhasil dilakukan dengan memanfaatkan Streamlit sebagai platform untuk hosting aplikasi model secara online.

IV. HASIL DAN PEMBAHASAN

4.1 Hasil dan Pengujian Model

Dalam penelitian ini, kami menggunakan model XGBoost dan Decision Tree C4.5 untuk memprediksi status kesehatan mental, khususnya terkait dengan kecenderungan bunuh diri. Evaluasi dilakukan dengan menggunakan data uji dan metrik-metrik evaluasi yang relevan seperti akurasi, precision, recall, dan F1-score.

a. Evaluasi Model Decision Tree C4.5 for Train Dataset

Pada model C4.5 dengan data training (80%), hasil evaluasi menunjukkan akurasi sebesar 92.90%. Precision model ini adalah 80.06% dan recall 81.61%, dengan F1-score 80.83%. Meskipun hasil keseluruhan cukup baik, ada ketidakseimbangan dalam mendeteksi individu yang tidak berisiko (non-suicidal) dan yang berisiko (suicidal). Model ini lebih baik dalam mendeteksi individu yang tidak berisiko, tetapi kesulitan dalam mengidentifikasi individu yang berisiko mengalami masalah kesehatan mental, seperti depresi atau kecenderungan bunuh diri.

b. Evaluasi Model Decision Tree C4.5 for Test Dataset

Model C4.5 pada data uji menghasilkan akurasi sebesar 92.47%. Precision model ini adalah 79.38% dan recall 81.58%, dengan F1-score mencapai 80.48%. Meskipun model menunjukkan performa yang baik, ada ketidakseimbangan dalam mendeteksi individu berisiko (suicidal) dan yang tidak berisiko (non-suicidal). Model ini cenderung lebih efektif dalam mendeteksi individu yang tidak berisiko, namun kesulitan dalam mendeteksi individu yang berisiko mengalami masalah kesehatan mental seperti depresi atau kecenderungan bunuh diri.

c. Evaluasi Model XGBoost fot Train Dataset

Model XGBoost pada data pelatihan menghasilkan akurasi sebesar 95.74%. Precision model ini adalah 89.39% dan recall 86.82%, dengan F1-score mencapai 88.08%. Model ini menunjukkan performa yang sangat baik, terutama dalam mendeteksi individu non-suicidal. Meskipun model ini cukup baik dalam mendeteksi individu berisiko, ada sedikit ruang untuk perbaikan pada deteksi individu yang berisiko mengalami masalah kesehatan mental, seperti depresi atau kecenderungan bunuh diri.

d. Evaluasi Model XGBoost fot Test Dataset

Model XGBoost pada data uji menghasilkan akurasi sebesar 93.23%. Precision model ini adalah 82.63% dan recall 80.15%, dengan F1-score mencapai 81.33%. Model ini menunjukkan performa yang baik, meskipun masih ada ruang untuk perbaikan dalam mendeteksi individu berisiko (suicidal). Meskipun precision tinggi, recall menunjukkan bahwa masih ada

beberapa individu berisiko yang tidak terdeteksi dengan baik oleh model ini.


e. Evaluasi Model XGBoost with Tuning Grid Search for Train Dataset

Model XGBoost dengan GridSearch pada data pelatihan menghasilkan akurasi sebesar 94.21%. Precision model ini adalah 85.27%, recall 82.76%, dan F1-score mencapai 83.75%. Model ini menunjukkan kemampuan yang sangat baik dalam mendeteksi individu non-suicidal dengan precision yang tinggi, serta cukup baik dalam mendeteksi individu berisiko (suicidal) dengan recall yang mencapai 82.76%.


f. Evaluasi Model XGBoost with Tuning Grid Search for Test Dataset

Model XGBoost dengan GridSearch pada data uji menghasilkan akurasi sebesar 93.92%. Precision model ini adalah 84.58%, recall 81.73%, dan F1-score mencapai 83.12%. Model ini menunjukkan performa yang baik dalam mendeteksi individu non-suicidal dengan precision yang tinggi. Recall yang mencapai 81.73% juga menunjukkan bahwa model cukup efektif dalam mendeteksi individu yang berisiko (suicidal), meskipun masih ada ruang untuk perbaikan dalam mendeteksi lebih banyak individu berisiko.

4.2 Interpretasi



Gambar 1. Grafik Perbandingan Model (Train Data)



Gambar 2. Grafik Perbandingan Model (Test Data)

Berdasarkan perbandingan metrik evaluasi antara model Decision Tree, XGBoost, dan XGBoost dengan GridSearch,

pada data uji, model XGBoost dengan GridSearch menunjukkan akurasi tertinggi sebesar 94%, dengan precision 85%, recall 82%, dan F1-score 83%. Hal ini menunjukkan bahwa GridSearch tuning telah meningkatkan performa model dengan memberikan keseimbangan yang lebih baik antara precision dan recall, serta memperbaiki kemampuan model dalam mendeteksi individu berisiko. Model XGBoost tanpa GridSearch juga menunjukkan performa yang baik dengan akurasi 93.24%, precision 84.57%, recall 81.73%, dan F1-score 83.12%. Meskipun ada sedikit penurunan pada data uji dibandingkan dengan data pelatihan, hasil ini menunjukkan bahwa XGBoost masih memberikan kinerja yang cukup stabil tanpa tuning tambahan.

Di sisi lain, model Decision Tree memiliki akurasi 92.71% pada data uji, dengan precision 80.06%, recall 81.61%, dan F1-score 80.83%. Meskipun cukup baik, model ini mengalami kesulitan dalam mendeteksi individu berisiko bunuh diri, yang tercermin pada recall yang lebih rendah dibandingkan precision. Ini menunjukkan bahwa model ini lebih baik dalam mendeteksi individu non-suicidal namun kurang efektif dalam mendeteksi kelas suicidal. Pada data pelatihan, hasilnya menunjukkan tren yang sama. Model XGBoost dengan GridSearch masih memiliki akurasi tertinggi, diikuti dengan precision dan recall yang seimbang serta F1-score yang lebih baik dibandingkan dengan model lainnya. XGBoost tanpa GridSearch juga menunjukkan hasil yang sangat baik, sementara Decision Tree menunjukkan akurasi yang sedikit lebih rendah dan ketidakseimbangan dalam deteksi kelas suicidal.

Secara keseluruhan, XGBoost dengan GridSearch adalah model terbaik yang memberikan performa yang lebih seimbang dan optimal pada kedua data (uji dan pelatihan), sementara Decision Tree memerlukan perbaikan dalam mendeteksi individu berisiko bunuh diri.

V. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini berhasil membangun model klasifikasi menggunakan algoritma XGBoost dan Decision Tree C4.5, dengan tambahan Grid Search untuk tuning hyperparameter, yang bertujuan untuk memprediksi apakah seseorang mengalami depresi atau tidak. Model-model yang dibangun diuji dengan data kesehatan mental dan dievaluasi menggunakan metrik-metrik seperti akurasi, precision, recall, dan F1-score. Hasil evaluasi menunjukkan bahwa XGBoost dengan GridSearch Tuning memberikan performa terbaik dengan akurasi 93.92%, precision 84.58%, recall 81.73%, dan F1-score 83.12%, yang menunjukkan kemampuan model dalam mendeteksi baik individu yang berisiko mengalami depresi maupun yang tidak. Sementara itu, Decision Tree C4.5, meskipun memiliki akurasi 92.71%, tidak seimbang dalam mendeteksi kelas minoritas (depresi), dengan F1-score yang lebih rendah.

Selain membangun model prediksi, penelitian ini juga berhasil menganalisis faktor-faktor dominan yang berkontribusi terhadap depresi menggunakan XGBoost. Hasil analisis menunjukkan bahwa Academic Pressure, Have you ever had suicidal thoughts?, Age, Job Satisfaction, merupakan faktor sosial, ekonomi, dan psikologis yang paling berpengaruh dalam memprediksi risiko depresi. Student dan Working Professional yang menghadapi tekanan tinggi dari akademik dan pekerjaan

menunjukkan kecenderungan lebih tinggi terhadap masalah kesehatan mental, terutama depresi. Faktor seperti stress score dan riwayat pikiran suicidal juga terbukti memiliki kontribusi signifikan.

Dengan demikian, hasil penelitian ini memberikan wawasan penting tentang faktor-faktor yang mempengaruhi kesehatan mental, serta pentingnya penggunaan model machine learning dalam mendeteksi dan memprediksi depresi. Penelitian ini juga dapat menjadi dasar untuk pengembangan aplikasi atau sistem yang dapat membantu deteksi dini masalah kesehatan mental, sehingga memberikan peluang bagi intervensi lebih cepat dan efektif dalam penanganan depresi.

5.2 Saran

Berdasarkan hasil yang diperoleh dalam penelitian ini, berikut beberapa saran yang dapat dipertimbangkan untuk pengembangan lebih lanjut:

1. Peningkatan Model dengan Data yang Lebih Beragam: Untuk meningkatkan akurasi model, penting untuk menggunakan data yang lebih bervariasi dan mencakup faktor-faktor lain yang mempengaruhi kesehatan mental, seperti faktor lingkungan sosial dan kebiasaan hidup.
2. Pengembangan Aplikasi Berbasis Model: Hasil penelitian ini dapat digunakan sebagai dasar untuk mengembangkan aplikasi yang dapat membantu deteksi dini depresi. Aplikasi ini akan memungkinkan intervensi lebih cepat dan efektif, dengan memberi peringatan pada individu berisiko.
3. Pengujian dengan Model Lain: Meskipun XGBoost dan C4.5 Decision Tree menunjukkan performa yang baik, pengujian dengan model lain seperti Random Forest atau SVM dapat memberikan wawasan lebih dalam mengenai akurasi model prediksi.
4. Peningkatan Keseimbangan Data: Teknik seperti oversampling atau SMOTE bisa digunakan untuk menyeimbangkan kelas dalam dataset, terutama mengingat ketidakseimbangan antara individu yang berisiko dan yang tidak.

VI. PEMBAGIAN PEKERJAAN

Anggota Kelompok	Bagian yang Dikerjakan
Jufourlisa Sirait	Business Understanding, Data Understanding, Data Preparation, Building Model, Deployment, Document, Paper, Poster
Kezia Hutagaol	Business Understanding, Data Understanding, Data Preparation, Building Model, Deployment, Document, Paper, Poster
Reinaldy Hutapea	Business Understanding, Data Understanding, Data Preparation, Building Model, Deployment, Document, Paper, Poster

Tennov Pakpahan	Business Understanding, Data Understanding, Data Preparation, Building Model, Deployment, Document, Paper, Poster
-----------------	---

REFERENSI

- [1] Riset Kesehatan Dasar (Riskesdas), "Laporan Riskesdas 2018 Nasional.pdf," *Lembaga Penerbit Balitbangkes*. p. hal 156, 2018. [Online]. Available: [https://repository.badankebijakan.kemkes.go.id/id/eprint/3514/1/Laporan Riskesdas 2018 Nasional.pdf](https://repository.badankebijakan.kemkes.go.id/id/eprint/3514/1/Laporan_Riskesdas_2018_Nasional.pdf)
- [2] W. Nugraha and A. Sasongko, "Hyperparameter Tuning pada Algoritma Klasifikasi dengan Grid Search Hyperparameter Tuning on Classification Algorithm with Grid Search," *Sist. J. Sist. Inf.*, vol. 11, no. 2, pp. 391–401, 2022, [Online]. Available: <http://sistemasi.ftik.unisi.ac.id>
- [3] S. A. Melina and C. K. Herbawani, "Faktor-Faktor yang Mempengaruhi Kesehatan Mental Remaja Selama Pandemi Covid-19 : Tinjauan Literatur," *Media Kesehat. Masy. Indones.*, vol. 21, no. 4, pp. 286–291, 2022, doi: 10.14710/mkmi.21.4.286-291.
- [4] A. Nisa and U. M. Area, "Pengaruh Stres Kerja terhadap Kesehatan Mental pada Karyawan di Perusahaan Multinasional," pp. 1–8.
- [5] R. P. Tresyani, D. W. Utomo, and N. Maldini, "Deteksi Dini Gangguan Kesehatan Mental dengan Model Bert dan Algoritma Xgboost," vol. 16, no. 01, pp. 93–98, 2025, doi: 10.35970/infotekmesin.v16i1.2535.
- [6] B. A. C. Permana, R. Ahmad, H. Bahtiar, A. Sudianto, and I. Gunawan, "Classification of diabetes disease using decision tree algorithm (C4.5)," *J. Phys. Conf. Ser.*, vol. 1869, no. 1, 2021, doi: 10.1088/1742-6596/1869/1/012082.
- [7] R. Wirth and J. Hipp, "CRISP-DM: towards a standard process model for data mining. Proceedings of the Fourth International Conference on the Practical Application of Knowledge Discovery and Data Mining, 29-39," *Proc. Fourth Int. Conf. Pract. Appl. Knowl. Discov. Data Min.*, no. 24959, pp. 29–39, 2000, [Online]. Available: https://www.researchgate.net/publication/239585378_CRISP-DM_Towards_a_standard_process_model_for_data_mining

LAMPIRAN

Berikut ini tampilan Form Prediksi Kesehatan Mental untuk Deployment Local

Form Prediksi Kesehatan Mental

Name:

Gender (0: Male, 1: Female):

Age:

City (numeric encoding):

Student or Working Professional (0/1):

Profession (numeric encoding):

Academic Pressure:

Work Pressure:

CGPA:

Study Satisfaction:

Job Satisfaction:

Sleep Duration:

Dietary Habits:

Degree (numeric encoding):

Suicidal Thoughts (0: No, 1: Yes):

Work/Study Hours:

Financial Stress:

Family History of Mental Illness (0/1):

Stress Score:

Prediksi

Berikut ini tampilan Form Prediksi Kesehatan Mental untuk Deployment Online

Mental Health Prediction App

Name

Gender (0=Female, 1=Male)

0

Age

18,00

City (Encoded)

0

Working Professional or Student (0=Student, 1=Working)

0

Profession (Encoded)

0

Academic Pressure

1,00

Work Pressure

1,00

CGPA

5,03

Study Satisfaction

1,00

Job Satisfaction

1,00

Sleep Duration (hours)

0,00

Dietary Habits (0=Unhealthy, 1=Moderate, 2=Healthy)

0,00

Degree (Encoded)

0

Have you ever had suicidal thoughts? (0=No, 1=Yes)

0

Work/Study Hours

0,00

Financial Stress

1,00

Family History of Mental Illness (0=No, 1=Yes)

0

isStudents (0=No, 1=Yes)

0

isWorkingProfessional (0=No, 1=Yes)

0

Stress Score

2,00

Predict